

《交通大数据分析与应用》

PEMS-BAY 课程数据包说明

学生版 | 请先阅读再开始分析

325 个检测站 | 5 分钟速度 | 2017 年 1—6 月

1. 先看这一页

本数据包用于《交通大数据分析与应用》课程项目。学生无需另行注册、下载或替换数据。课程项目中应使用本数据包的固定版本，以保证不同小组的结果可以比较。

数据记录的是 325 个高速公路检测站的 5 分钟平均速度。时间范围为 2017 年 1 月 1 日 00:00 至 2017 年 6 月 30 日 23:55，共 52,116 个时间点。数据采用“宽表”结构：每一行是一个时间点，每一个检测站编号是一列。

重要边界：本数据包只有速度、检测站坐标和站点间距离关系，没有流量、占有率、车道数、事故、天气、道路施工或控制措施数据。因此可以分析运行状态、时空关联、预测和预警，但不能仅凭本数据证明拥堵原因或某项措施的因果效果。

2. 文件清单

文件	内容	是否用于正式分析
pems_bay_speed.csv.gz	325 个检测站的完整 5 分钟速度矩阵	是，主数据
stations.csv	检测站编号、列顺序、纬度和经度	是，站点表
sensor_distances.csv.gz	有向站点对其距离值	空间任务使用
sensor_ids_bay.txt	与速度矩阵完全一致的 325 个检测站编号	程序核对使用
known_data_issues.csv	已知时间缺口和 0 值记录清单	数据质量核查使用
字段字典.csv	各文件字段、单位、粒度和注意事项	是
preview_2days_12sensors.csv	2 天、12 个站点的读取测试样例	仅测试，不可代替正式数据
load_data_example.py	读取与结构检查示例	建议先运行
manifest_sha256.csv	文件大小与 SHA-256 校验值	文件核验使用

压缩 CSV 可直接由 Pandas 读取，不需要先手工解压。

3. 主数据怎样理解

3.1 pems_bay_speed.csv.gz

- 观测单位：一个检测站在一个 5 分钟时间点的平均速度；
- 行：52,116 个时间点；
- 检测站列：325 列；
- timestamp：数据中记录的当地日期时间，文件本身未写入时区偏移；
- 其余列名：检测站编号；
- 数值单位：英里/小时（mph）。

例如，400001 列在某一行的数值是检测站 400001 在该时间点的速度，不是流量，也不是车辆数。

3.2 stations.csv

每行对应一个检测站：

- sensor_order：该站点在速度矩阵中的列序号，从 0 开始；
- sensor_id：检测站编号，应按字符串读取；
- latitude、longitude：WGS84 经纬度，可用于绘制点位分布。

检测站是点观测位置，不等同于完整道路路段。仅凭经纬度也不能判断行驶方向、车道类型或道路功能。

3.3 sensor_distances.csv.gz

每行表示一个有向站点对：

- from_sensor_id：起点检测站；
- to_sensor_id：终点检测站；
- distance：原始仓库提供的距离值。

该文件不是所有站点两两组合的完整距离矩阵，from → to 与 to → from 也不一定同时存在。课程审计表明其数量级与米一致，但上游文件没有明确写出单位，因此本课程将其主要作为相对距离和图连接依据。不得把它直接解释为精确道路里程、行驶时间或上下游方向。

4. 已知数据质量问题

4.1 时间并非完全连续

全时段按 5 分钟应有 52,128 个时间标签，数据实际有 52,116 个。2017 年 3 月 12 日 02:00 至 02:55 的 12 个时间标签共同缺失，前后形成一次 65 分钟间隔。这个全网同步缺口与当地时间切换相符，不应直接解释为 325 个检测器同时故障。

进行滞后、滚动窗口、持续时间或预测分析时，应先检查相邻时间差是否确为 5 分钟。不要在没有说明的情况下把缺少的 12 行自动补成正常速度。

4.2 0 值需要单独处理

完整速度矩阵中没有空白值，但有 304 个 0 值，分布在 230 个检测站。0 值既可能表示编码的无效或缺失观测，也可能被误解为真实完全停车。建议将 0 值先标记为数据质量候选，并至少比较以下两种处理对结论的影响：

1. 将 0 值暂按缺失值处理；
2. 保留 0 值，但在图表和评价指标中单独说明。

不建议直接用 0 值计算 MAPE；分母为 0 会使结果失真。

4.3 不能从现有字段判断的内容

本数据包不能直接判断：

- 某次低速是否由事故、天气、施工或需求增长造成；
- 检测站属于哪条道路、哪个方向或哪类车道；
- 道路通行能力、流量—密度关系或车辆延误总量；
- 某项管理措施实施后的因果效果。

这些内容可以作为局限和后续数据需求提出，但不能作为已经由本数据验证的结论。

5. 最小读取示例

```
python
from pathlib import Path
import pandas as pd
```

```

data_dir = Path("学生数据包")

speed = pd.read_csv(
    data_dir / "pems_bay_speed.csv.gz",
    parse_dates=["timestamp"]
)

stations = pd.read_csv(
    data_dir / "stations.csv",
    dtype={"sensor_id": "string"}
)

distances = pd.read_csv(
    data_dir / "sensor_distances.csv.gz",
    dtype={"from_sensor_id": "string", "to_sensor_id": "string"}
)

print(speed.shape)    # (52116, 326): 1 个时间列 + 325 个站点列

print(stations.shape) # (325, 4)

print(distances.shape) # (8358, 3)

```

如果需要把宽表转换为“时间—站点—速度”长表，可以只转换本组所需的站点和时间范围，避免不必要的内存占用。

```

python

chosen = ["400001", "400017", "400030"]

long_speed = speed[["timestamp", *chosen]].melt(
    id_vars="timestamp",
    var_name="sensor_id",
    value_name="speed_mph"
)

```

6. 开始分析前必须完成的检查

3. 明确分析对象是“检测站”“检测站—时间”还是“拥堵事件”；
4. 核对站点编号是否在三个数据文件中一致；
5. 说明 0 值处理规则；

- 6.检查滚动窗口是否跨越了 65 分钟时间间隔;
- 7.预测或预警任务按时间划分训练、验证和检验数据, 不得随机打乱后再切分;
- 8.先建立简单基准, 再判断复杂方法是否真正带来改善;
- 9.将结论限制在速度运行状态, 不把相关性写成因果性。

7. 参考资料

课程数据的结构与站点空间文件参照 DCRNN 项目公开资料整理:

- DCRNN 项目说明: <https://github.com/liyaguang/DCRNN>
- PEMS-BAY 检测站坐标: https://github.com/liyaguang/DCRNN/blob/master/data/sensor_graph/graph_sensor_locations_bay.csv
- DCRNN 论文: <https://arxiv.org/abs/1707.01926>

以上链接供理解数据背景使用。课程作业不要求重新下载数据, 也不要求在个人报告中重复介绍数据来源。